



Nama : Muhammad Dhiauddin
NIM : 25917024
Program : Magister Informatika
Konsentrasi : Sains Data Profesional
Domain : Kesehatan
Studi Kasus : Rumah Sakit Umum Daerah Datu Sanggul

BIG DATA ANALYTICS

“Analysis Automated ICD-10 Diagnosis Coding Menggunakan Big Data Analytics dan Machine Learning”

BAB 1. Pendahuluan

1.1 Latar Belakang

Unit rekam medis pada rumah sakit memegang peran penting dalam proses kodefikasi diagnosis, termasuk penerapan standar ICD-10 untuk keperluan klaim, pelaporan, dan audit klinis. Pada studi kasus ini, proses ekstraksi diagnosis dan penentuan kode ICD-10 masih memiliki beban kerja tinggi karena dilakukan secara manual pada narasi rekam medis. Kondisi ini berpotensi menimbulkan keterlambatan dan inkonsistensi kualitas data klinis.

Dataset yang dianalisis menunjukkan skala operasional yang besar, yaitu 24.806 rekam medis yang dapat digunakan untuk kebutuhan pilot otomasi dan evaluasi model berbasis data. Dalam konteks Big Data, pemrosesan skala ini relevan karena melibatkan data tekstual narasi medis, multi-label diagnosis, dan kebutuhan analitik yang beragam (klasifikasi, peramalan, dan kategorisasi).

1.2 Rumusan Masalah

Rumusan masalah penelitian ini adalah bagaimana membangun analisis Big Data yang mampu:

1. meningkatkan efisiensi proses coding diagnosis ICD-10,
2. menyediakan mekanisme kontrol kualitas (validity check) hasil mapping, dan
3. membantu perencanaan sumber daya melalui peramalan beban kerja.

1.3 Tujuan Penelitian

Tujuan penelitian ini meliputi:

1. Mengidentifikasi kebutuhan keputusan organisasi terkait otomasi kodefikasi ICD-10 pada SIMRS.
2. Menggabungkan dua sumber data (rekam medis SIMRS dan katalog ICD-10) untuk mendukung analisis.
3. Mengimplementasikan pipeline analitik menggunakan PySpark untuk pengolahan data, feature engineering, dan evaluasi model.
4. Merancang dashboard untuk penyajian KPI dan hasil model agar mudah dipahami stakeholder.



1.4 Ruang Lingkup dan Batasan

- 1. Data yang digunakan adalah data sekunder dari SIMRS dan katalog ICD-10, dengan validasi kualitas data berupa pengecekan missing value, rentang tanggal, serta statistik demografi dasar.
- 2. NLP yang digunakan pada tahap baseline menggunakan pendekatan keyword-based entity extraction (heuristic), sehingga performanya diperlakukan sebagai baseline untuk perbaikan lebih lanjut di tahap produksi.
- 3. Tiga model dibangun untuk tujuan yang berbeda (validity check, forecasting, dan kategorisasi multi-kelas), sehingga interpretasi keberhasilan mempertimbangkan konteks task dan metrik yang sesuai.

BAB 2. Domain & Keputusan Organisasi (S.M.A.R.T)

2.1 Domain yang Dipilih

Domain penelitian adalah Sistem Informasi Manajemen Rumah Sakit (SIMRS) pada unit rekam medis, dengan fokus pada “Automated ICD-10 Clinical Coding” menggunakan Natural Language Processing dan Machine Learning. Studi kasus berada di RSUD Datu Sanggul, Kabupaten Tapin, Kalimantan Selatan.

2.2 Keputusan Organisasi (Pertanyaan Bisnis)

Keputusan organisasi yang didukung oleh analitik Big Data adalah:

Apakah implementasi NLP-based coding assistant dapat meningkatkan akurasi kode ICD dan mempercepat proses coding diagnosis sehingga berdampak pada kualitas klaim/pelaporan serta efisiensi sumber daya?

2.3 S.M.A.R.T Questions

Tabel berikut merangkum S.M.A.R.T Questions untuk memastikan keputusan organisasi terukur dan realistis.

Dimensi	Rumusan	Target/Indikator
Specific	Implementasi coding assistant untuk meningkatkan akurasi ICD dan mempercepat proses coding.	Peningkatan akurasi dan kecepatan terukur.
Measurable	(i) Akurasi model vs ground truth, (ii) turnaround time per berkas, (iii) throughput per coder.	Target akurasi 85%, 5 menit/berkas, throughput 2x.
Achievable	Ketersediaan data 24.806 rekam medis dan infrastruktur Spark untuk pilot.	Pilot 5.000–20.000 berkas feasible.



Dimensi	Rumusan	Target/Indikator
Relevant	Relevansi ke kualitas klaim/pelaporan dan penurunan error coding.	Target penurunan reject/ketidaksesuaian 15–20% → 5%.
Time-bound	Implementasi pilot dalam rentang waktu tertentu.	8–12 minggu (Q1 2026).

BAB 3. Data & Sumber Data

3.1 Sumber Data

Penelitian menggunakan minimal dua sumber data:

- Dataset 1 – Rekam Medis SIMRS (internal):** memuat informasi pasien/kunjungan/narasi rekam medis/diagnosis terstruktur. Total record: 24.806.
- Dataset 2 – Katalog ICD-10 (eksternal/resmi):** memuat 18.543 kode ICD-10, dengan kolom CODE, DISPLAY, dan VERSION.

3.2 Deskripsi Dataset 1 (SIMRS)

Dataset rekam medis SIMRS berisi kolom antara lain: idpasien, nmpasien, jk, umurpasien, idkunjungan, tglregistrasi, nmdokter, rekammedisnarasi, diagnosisstructured. Total record yang berhasil diload adalah 24.806.

3.3 Deskripsi Dataset 2 (Katalog ICD-10)

Katalog ICD-10 berisi 18.543 kode ICD-10 versi ICD102010 dengan atribut CODE, DISPLAY, dan VERSION. Dataset ini digunakan sebagai referensi/standar terminologi dan validasi mapping.

3.4 Validasi Kualitas Data

Hasil pemeriksaan kualitas data menunjukkan:

- Total record dataset SIMRS: 24.806.
- Missing pada kolom rekammedisnarasi: 2.121 record.
- Missing pada kolom diagnosisstructured: 2.123 record.
- Dataset ICD-10 memiliki total 18.543 kode dan 1 versi (ICD102010).

BAB 4. Metodologi dan Implementasi Analitik Big Data (PySpark)

4.1 Rancang Pipeline Analitik

Secara umum pipeline penelitian adalah:

- Inisialisasi Spark dan library (PySpark + Spark NLP).
- Load dataset SIMRS dan ICD-10, dilanjutkan validasi kualitas data.

3. EDA ringkas untuk memahami distribusi demografi dan diagnosis dominan.
4. NLP baseline: ekstraksi entitas klinis menggunakan pendekatan keyword-based (heuristic).
5. Ground truth preparation: explode diagnosis menjadi multi-label untuk membangun dataset analitik.
6. Feature engineering untuk membentuk fitur numerik/kategorikal.
7. Pemodelan: XGBoost (binary), Prophet (time series), Random Forest (multi-class).
8. Evaluasi model dan perumusan insight untuk stakeholder + rancangan dashboard.

4.2 Exploratory Data Analysis (EDA)

Ringkasan EDA menunjukkan adanya diagnosis dominan tertentu serta statistik demografi dasar (usia dan gender). Selain itu, dilakukan analisis top diagnosis/keyword untuk memahami fokus kasus yang paling sering muncul sehingga membantu desain fitur dan interpretasi model.

4.3 NLP Baseline dan Ground Truth Preparation

4.3.1 Ground truth (multi-label)

Diagnosis terstruktur dipisah (split) dan di-*explode* menjadi entri per diagnosis sehingga total entri diagnosis menjadi 65.476, dengan jumlah pasien unik 8.198. Pendekatan ini relevan untuk kasus multi-label karena satu kunjungan dapat memuat beberapa diagnosis.

4.3.2 Keyword-based NER (baseline)

NLP baseline dibangun dengan kamus keyword per kategori klinis (mis. IGD, jantung, paru, THT, obgyn, dsb.) untuk mendeteksi entitas pada narasi klinis. Pendekatan ini digunakan sebagai baseline karena mudah diimplementasikan dan dapat dijalankan cepat pada data skala besar, namun memiliki keterbatasan dibanding model pretrained NER klinis.

4.3.3 Validasi baseline NLP

Hasil validasi menunjukkan total entri ground truth 65.476, matched dengan NER sebanyak 11.107, sehingga akurasi baseline 16,96%. Nilai ini diperlakukan sebagai baseline untuk menunjukkan tingkat kesulitan ekstraksi diagnosis dari narasi bebas serta kebutuhan peningkatan (mis. fine-tuning model transformer klinis).

4.4 Feature Engineering

Fitur yang direkayasa untuk modeling meliputi:

1. *narrativelength*: panjang teks narasi.
2. *narrativewords*: jumlah kata pada narasi.
3. *numdiagnosis*: jumlah diagnosis per kunjungan (dari *diagnosisstructured*).
4. *umurpasien* dan *agegroup*: fitur demografi (infant/child/adult/senior).
5. *entitycount*: jumlah entitas terdeteksi dari keyword-based NER.
6. *dayofweek*, *month*, *year*: fitur temporal dari *tglregistrasi*.



7. Target `isvalidmapping`: indikator biner hasil `matching baseline` (digunakan sebagai label untuk model 1).

Ringkasan statistik fitur menunjukkan rata-rata `narrativelength` sekitar 338,81 karakter, `narrativewords` 45,34 kata, `numdiagnosis` 3,61, `umurpasien` rata-rata 47,31, serta `entitycount` rata-rata 2,32.

BAB 5. Hasil dan Pembahasan

5.1 Model 1 — XGBoost (Binary Classification: Validity Check)

5.1.1 Tujuan

Model 1 bertujuan memprediksi apakah suatu diagnosis memiliki mapping yang “valid” terhadap baseline ground truth/NER (biner: valid vs invalid) sebagai mekanisme kontrol kualitas awal sebelum proses otomasi lanjutan.

5.1.2 Dataset dan split

Data modeling berjumlah 65.476 record, dengan train-test split 80:20 (training 52.224 dan test 13.252). Fitur yang digunakan: `narrativelength`, `narrativewords`, `numdiagnosis`, `umurpasien`, `entitycount`.

5.1.3 Evaluasi

Hasil evaluasi XGBoost:

- 1. Accuracy: 83,08%
- 2. Precision: 72,79%
- 3. Recall: 4,63%
- 4. F1-score: 8,71%
- 5. AUC-ROC: 0,7525
- 6. Confusion matrix: TP 107, FP 40, TN 10.903, FN 2.202

5.1.4 Interpretasi

Akurasi model menunjukkan kemampuan klasifikasi umum yang baik, namun recall sangat rendah sehingga banyak kasus valid tidak terdeteksi (false negatives). Dengan karakteristik ini, model lebih tepat digunakan sebagai *pre-filter* dan *quality audit tool* (menandai kasus tertentu untuk review manual), bukan sebagai validator tunggal yang “mengunci” keputusan mapping klinis.

5.2 Model 2 — Facebook Prophet (Time Series Forecasting)

5.2.1 Tujuan

Model 2 bertujuan memprediksi tren dan beban kerja diagnosis harian untuk perencanaan sumber daya (resource planning), misalnya penjadwalan coder dan estimasi kapasitas proses.



5.2.2 Data time series

Data time series disiapkan selama 140 hari, dengan rentang 2025-01-01 sampai 2025-05-23, menggunakan target totaldiagnosis harian.

5.2.3 Evaluasi

Hasil evaluasi Prophet:

- 1. RMSE: 884,99 diagnosis/hari
- 2. MAE: 629,63 diagnosis/hari
- 3. MAPE: 1044,85
- 4. R-squared: 0,3907
- 5. Tren: slope 238,0830 (INCREASING)
- 6. Statistik forecast 30 hari: rata-rata 1.740 diagnosis/hari; total kumulatif 52.213 (30 hari).

5.2.4 Interpretasi

Nilai R^2 0,3907 menunjukkan model menjelaskan sebagian variasi data, namun masih terdapat faktor eksternal/variabilitas tinggi yang belum tertangkap. MAPE yang sangat besar dapat terjadi saat terdapat hari dengan nilai aktual sangat kecil sehingga persentase error menjadi ekstrem. Secara praktis, hasil ini dapat dijadikan baseline forecasting untuk diskusi kapasitas, namun perlu refinement sebelum menjadi dasar keputusan operasional kritikal.

5.3 Model 3 — Random Forest (Multi-class Classification: 16 Kategori)

5.3.1 Tujuan

Model 3 bertujuan mengklasifikasikan diagnosis ke dalam kategori/poliklinik (16 kelas) untuk membantu routing kasus, pengelompokan layanan, dan dukungan keputusan klinis berbasis kategori.

5.3.2 Evaluasi

Hasil evaluasi Random Forest:

- 1. Accuracy: 84,57%
- 2. Weighted Precision: 85,18%
- 3. Weighted Recall: 84,57%
- 4. Weighted F1-score: 83,05%
- 5. Feature importance (top): narrativelength 0,3499; narrativewords 0,2457; numdiagnosis 0,2085; umurpasien 0,1428; entitycount 0,0531.

5.3.3 Interpretasi

Model multi-kelas menunjukkan metrik yang seimbang (precision/recall/F1) sehingga lebih stabil untuk implementasi kategorisasi. Dominasi fitur berbasis teks (narrativelength,



narrativewords) dan kompleksitas kunjungan (numdiagnosis) menunjukkan bahwa struktur narasi dan jumlah diagnosis memberi sinyal kuat untuk menentukan kategori.

5.4 Perbandingan Model dan Implikasi Keputusan

Tabel ringkas berikut merangkum peran tiap model agar stakeholder memahami bahwa metrik antar model tidak dibandingkan secara “apple-to-apple” karena task berbeda.

Model	Task	Primary Metric	Secondary Metric	Use Case
XGBoost	Binary classification	83,08% Accuracy	0,7525 AUC	Validity check / quality audit. enhanced_analysis_diagnosis_icd_based.ipynb
Prophet	Time series regression	0,3907 R ²	884,99 RMSE	Resource planning / forecasting beban kerja. enhanced_analysis_diagnosis_icd_based.ipynb
Random Forest	Multi-class classification	84,57% Accuracy	83,05% Weighted F1	Routing/kategorisasi 16 kategori. enhanced_analysis_diagnosis_icd_based.ipynb

BAB 6. Rancangan Dashboard Stakeholder

6.1 Tujuan Dashboard

Dashboard ditujukan untuk menyajikan hasil analitik secara ringkas melalui KPI, visualisasi metrik model, dan ringkasan kualitas data sehingga memudahkan stakeholder (manajemen, unit rekam medis, IT) memahami performa model serta kesiapan implementasi.

6.2 Komponen Dashboard (berdasarkan app.py)

Dashboard berbasis Streamlit menampilkan:

- Header KPI dataset (Total pasien, total diagnosis, total kode ICD-10).
- KPI performa model: XGBoost (binary), Prophet (R²), Random Forest (multi-class), serta akurasi NLP baseline.
- Visual perbandingan model (bar chart), confusion matrix model 1, feature importance model 1 dan 3, pie chart NLP validation, serta distribusi diagnosis.
- Bagian tambahan: data quality assessment, ringkasan feature engineering, business case/ROI, roadmap implementasi, risk mitigation, dan success metrics.

6.3 Cara Menjalankan Dashboard

Jalankan dashboard:
pip install streamlit pandas numpy plotly
streamlit run app.py



Catatan: script dashboard memiliki fallback data dummy jika file CSV tidak ditemukan, sehingga tetap dapat dipakai untuk demo/presentasi tanpa error pada lingkungan penilai.

BAB 7. Kesimpulan dan Rekomendasi

7.1 Kesimpulan

Penelitian ini berhasil menyusun pipeline Big Data Analytics berbasis PySpark untuk mendukung otomasi dan kontrol kualitas kodefikasi diagnosis ICD-10 pada SIMRS. Dataset utama berjumlah 24.806 record SIMRS dan 18.543 kode ICD-10, serta dibentuk menjadi dataset analitik 65.476 entri diagnosis melalui proses explode multi-label.

Dari sisi pemodelan, XGBoost memberikan kinerja klasifikasi biner dengan akurasi 83,08% dan AUC 0,7525 sebagai validity check, Prophet memberikan baseline forecasting dengan R^2 0,3907 untuk perencanaan beban kerja, dan Random Forest memberikan performa multi-kelas 84,57% accuracy (weighted F1 83,05%) untuk kategorisasi 16 kelas.

7.2 Rekomendasi

1. Tingkatkan NLP dari keyword-based baseline ke pendekatan klinis yang lebih kuat (misalnya pretrained NER klinis + human-in-the-loop) untuk meningkatkan akurasi ekstraksi dan mengurangi gap baseline 16,96%.
2. Terapkan strategi penanganan imbalance kelas pada multi-class (mis. class weighting, hierarchical classification) bila distribusi kategori tidak merata pada data nyata.
3. Refinement forecasting: evaluasi ulang MAPE, gunakan transformasi/penanganan nilai kecil, serta uji model alternatif untuk time series agar prediksi lebih reliabel untuk keputusan operasional.
4. Implementasikan monitoring produksi (drift, data quality, metrik harian) pada dashboard agar sistem dapat dipelihara secara berkelanjutan.