

ANALYSIS DIAGNOSIS ICD-10 BASED

NIM : 25917024

By Muhammad Dhiauddin

DOMAIN : Kesehatan – Rekam Medis

STUDI KASUS : RSUD DATU SANGGUL

MASALAH & SOLUSI

Solusi: Implementasi NLP + Machine Learning untuk otomatisasi kodefikasi diagnosis ICD-10

Aspek	Data
Volume Pasien	5,000-6,000 pasien/bulan → 24,806 rekam medis (3 bulan)
Proses Manual	1-2 menit per rekam = 150-300 jam per bulan
Error Rate	15-20% klaim BPJS ditolak
Delay Pelaporan	2-4 minggu pelaporan dari Tim JKN & RM ke BPJS
Dampak	Beban kerja tim coding overload, akurasi rendah, ROI BPJS hilang

S.M.A.R.T QUESTIONS

Kerangka Pertanyaan Bisnis

Specific

- Apakah implementasi NLP-based coding assistant dapat meningkatkan akurasi kode ICD dan mempercepat proses coding?

Measurable

- Akurasi model vs ground truth: $\geq 85\%$
- Waktu per berkas: ≤ 5 menit $\rightarrow < 1$ detik
- Throughput: 2x lipat

Achievable

- ✓ Dataset: 24,806 rekam medis + 18,543 kode ICD
- ✓ Infrastructure: Apache Spark + NLP
- ✓ Data volume: Sufficient untuk pilot 5,000–20,000 berkas

Relevant

- Reduce BPJS claim rejection rate: 15–20% $\rightarrow < 5\%$

Time-bound

- Q1 2026: 8–12 minggu pilot, akurasi $\geq 85\%$, time savings $\geq 30\text{--}40\%$

DATA OVERVIEW

Data Loading & Validation

Dataset 1: Rekam Medis Pasien (SIMRS)

- **Total Records** : 24,806 pasien
- **Periode** : 01 Januari – 09 Mei 2025
- **Fitur** : ID Pasien, Nama Pasien, Usia, JK, ID Kunjungan, Dokter, Narasi Medis, Diagnosis
- **Missing Data** : 2,121 narasi (8.5%), 2,123 diagnosis (8.5%)
- **Usia Range** : 0–2019 tahun (mean=43.99)
- **Gender** : L=11,326 (45.6%), P=13,480 (54.4%)

Dataset 2: Katalog ICD-10 Resmi Satu Sehat Kemenkes versi 2010 ([Link](#))


- Total Kode : 18,543 kode ICD-10
- Versi : ICD-10 2010
- Format : CODE, DISPLAY, VERSION

Status : ✓ Data validation completed successfully

NLP PIPELINE

Clinical NER & Ground Truth Preparation

NPL



Preprocessing

- 1.Explode Diagnosis: Multi-label diagnosis per record (65,476 entries total)
- 2.Clinical NER: Keyword-based entity extraction dari medical narrative
- 3.16 Kategori Poliklinik Mapping

Ground Truth Validation Results

Metrik	Hasil
Total Diagnosis Entries	65,476
Matched with NER	11,107 (16.96%)
Accuracy	16,96%

RSUD DATU SANGGUL



16 KATEGORI POLIKLINIK (MODEL 3 TARGET)

1. IGD (13,488) – INSTALASI GAWAT DARURAT
2. OTHER (5,653) – DIAGNOSIS LAINNYA
3. GERIATRI (652) – PENYAKIT LANSIA
4. FISIOTERAPI (635) – REHABILITASI
5. PARU (481) – PENYAKIT PARU
6. MATA (364) – PENYAKIT MATA
7. BEDAH (288) – OPERASI
8. THT (269) – TELINGA, HIDUNG, TENGGOROKAN
9. JANTUNG (203) – PENYAKIT JANTUNG
10. ANAK (181) – PEDIATRI
11. JIWA (151) – PSIKIATRI
12. KULT_KELAMIN (134) – DERMATOLOGI
13. SARAF (112) – NEUROLOGI
14. TUMBUH_KEMBANG (58) – PERKEMBANGAN ANAK
15. OBGYN (11) – OBSTETRI/GINEKOLOGI
16. HEMODIALISIS (5) – GINJAL TERMINAL

FEATURE ENGINEERING

8 FEATURES UNTUK ML MODELS

STATISTIK FITUR:

- **NARRATIVELENGTH: MEAN=338.81 CHARS, MIN=125, MAX=2040**
- **NARRATIVEWORDS: MEAN=45.33 WORDS, MIN=17, MAX=295**
- **NUMDIAGNOSIS: MEAN=3.61, MIN=-1, MAX=15**
- **ENTITYCOUNT: MEAN=2.31 ENTITIES, MIN=1, MAX=9**

No	Fitur	Tipe	Keterangan
1	narrative_length	Numerik	Panjang narasi medis (chars)
2	narrative_words	Numerik	Jumlah kata dalam narasi
3	num_diagnosis	Numerik	Jumlah diagnosis per kunjungan
4	umur_pasien	Numerik	Usia pasien (tahun)
5	age_group	Kategorik	Infant, Child, Adult, Senior
6	entity_count	Numerik	Jumlah entitas klinis terdeteksi
7	is_valid_mapping	Binary	Diagnosis valid untuk ICD-10
8	day_of_week	Kategorik	Hari registrasi (temporal)

XGBOOST CLASSIFIER

Prediksi Keberhasilan Matching NER vs Ground Truth (Binary Classification)

Tujuan :

Memprediksi apakah hasil NER keyword-based akan match dengan diagnosis ground truth, bukan langsung “valid ICD-10 mapping”.

Arsitektur :

- Algoritma: XGBoost Classifier
- Training Data: 52,224 baris (80%)
- Test Data: 13,252 baris (20%)
- Features: narrative_length, narrative_words, num_diagnosis, umur_pasien, entity_count

Performance Metrics	
Metrik	Nilai
Accuracy	83,08%
Precision	72,79%
Recall	4,63%
F1-Score	8,71%
AUC-ROC	0,7525

Confusion Matrix (kelas “Valid”):

True Positive (TP): 107
False Negative (FN): 2,202

XGBOOST CLASSIFIER

Feature Importance (Gain-based)

- 1.entity_count: 0.7984 ($\approx 79.84\%$)
- 2.num_diagnosis: 0.0701
- 3.narrative_length: 0.0469
- 4.umur_pasien: 0.0431
- 5.narrative_words: 0.0414

Interpretasi Akademik

- Model memiliki akurasi total tinggi (83%), tetapi recall untuk kasus match (positif) sangat rendah (4.63%) $\rightarrow$ banyak kasus match yang tidak terdeteksi.
- Dominasi fitur entity_count mengindikasikan adanya kedekatan kuat antara fitur dan label (potensi leakage konseptual).
- Cocok diposisikan sebagai analisis baseline NER matching, bukan model final untuk valid ICD-10 mapping.

Use Case yang Masih Masuk Akal

✓ Analisis faktor apa yang mempengaruhi keberhasilan NER keyword-based.

FACEBOOK PROPHET

Trend Forecasting Beban Kerja Coding (Time Series)

Tujuan

Memprediksi trend jumlah diagnosis per hari (total_diagnosis) untuk kebutuhan resource planning.

Data Time Series

Horizon data: 140 hari (01 Jan – 23 Mei 2025)

Kolom agregat harian: daily_visits, avg_diagnosis_per_visit, total_diagnosis

Arsitektur

Algoritma: Facebook Prophet

Seasonality: weekly_seasonality = True, yearly=False, daily=False

Target: total_diagnosis per hari (kolom y)

FACEBOOK PROPHET

Performance Metrics :

Metrik	Nilai
RMSE	884,99
MAE	629,63
MAPE	1044,85%
R-squared	0,3907

Interpretasi Akademik :

- R^2 0.39: hanya $\approx 39\%$ variasi data yang mampu dijelaskan model $\rightarrow$ performa lemah.
- MAPE sangat besar (1044%) karena ada hari dengan nilai diagnosis sangat kecil (membuat error persen meledak).
- Prophet dalam konfigurasi saat ini belum layak dipromosikan sebagai "model unggulan". Perlu:
- Evaluasi di test set terpisah (bukan hanya training window).
- Perbaiki metrik (mis. SMAPE/MASE) dan penambahan regressor (daily_visits).

Use Case

✓ Exploratory forecasting untuk melihat pola kasar trend dan seasonality, bukan sebagai angka pasti untuk keputusan SDM.

RANDOM FOREST

Prediksi Kategori Diagnosis (Multi-class Classification)

Tujuan

Mengategorisasi diagnosis ke beberapa kategori klinis (multi-class) berdasarkan fitur jumlah diagnosis, panjang narasi, umur, dan entity_count.

Catatan: Implementasi saat ini menghasilkan 3 kelas efektif (konfirmasi dari confusion matrix 3×3), bukan 16 poli penuh.

Arsitektur

- Algoritma: Random Forest Classifier (Spark ML)
- Num Trees: 50
- Max Depth: 10
- Training Data: 80%
- Test Data: 20%

Performance Metrics

Metrik	Nilai
Accuracy	84,57%
Weighted Precision	85,18%
Weighted Recall	84,57%
Weighted F1-Score	83,05%

RANDOM FOREST

Feature Importance (Top 5)

- 1.narrative_length: 0.3499
- 2.narrative_words: 0.2457
- 3.num_diagnosis: 0.2085
- 4.umur_pasien: 0.1428
- 5.entity_count: 0.0531

Interpretasi Akademik

- Performa multi-class cukup baik untuk pilot (Accuracy 84.57%, F1 83.05%).
- Model sensitif terhadap kompleksitas teks (narrative_length, narrative_words) dan jumlah diagnosis.
- Klaim “16 poliklinik” belum didukung penuh oleh implementasi saat ini → di presentasi sebaiknya disebut “multi-class kategori klinis (saat ini 3 kelas utama)”.

MODEL COMPARISON & SELECTION

Perbandingan 3 Model (Hasil Aktual)

Aspek	Model 1 (XGBoost)	Model 2 (Prophet)	Model 3 (Random Forest)
Task	Binary Classification (NER match)	Time Series Regression	Multi-class Classification
Primary Metric	83.08% Accuracy	R ² = 0.3907	84.57% Accuracy
Secondary	AUC-ROC = 0.7525	RMSE = 884.99, MAPE>1000%	F1-Score (weighted) = 83.05%
Kekuatan	Menangkap pola NER match	Menangkap seasonality	Kinerja stabil di multi-class
Kelemahan	Recall positif sangat rendah	Error sangat besar	Saat ini baru mencakup 3 kelas

Kesimpulan Teknis

- Model 3 (Random Forest) adalah kandidat utama untuk kategorisasi diagnosis multi-class.
- Model 1 (XGBoost) bermanfaat untuk analisis keberhasilan NER match, bukan final ICD-10 validator.
- Model 2 (Prophet) masih perlu revisi lebih lanjut sebelum dipakai sebagai dasar keputusan operasional.

DASHBOARD VISUALIZATION

Elemen Dashboard yang Direkomendasikan

1. Model Performance Comparison (Bar Chart)

- Akurasi Model 1, Model 3
- R^2 Model 2 (ditandai dengan catatan “underperforming”)

2. Confusion Matrix & Class Metrics

- Confusion matrix Model 3 (3 kelas) untuk melihat pola salah klasifikasi

3. Feature Importance

- Horizontal bar untuk 5 fitur teratas Model 1 dan Model 3

4. Diagnosis Category Distribution

- Distribusi jumlah diagnosis per kategori (IGD, OTHER, dll.)

5. NLP Validation Summary

- Pie chart: Matched (16.96%) vs Not Matched (83.04%)

6. Time Series Overview

- Plot actual vs forecast Prophet sebagai insight eksplorasi (dengan label “model masih perlu penyempurnaan”).

BUSINESS RECOMMENDATIONS

Perbaikan & Pengembangan Lanjutan

1. Peningkatan NLP (NER)

- Beralih dari keyword-based ke pretrained clinical transformers (BioBERT, ClinicalBERT).
- Target peningkatan akurasi NER dari 16.96% → 50–60%+.

2. Re-definisi Label Model 1

- Ganti target dari `match_with_gt` menjadi indikator validitas mapping terhadap katalog ICD-10 resmi.
- Hal ini mengurangi risiko circularity dan meningkatkan relevansi model terhadap kebutuhan coding ICD.

3. Penyempurnaan Time Series Model

- Evaluasi Prophet pada test set terpisah dan gunakan metrik yang lebih stabil (SMAPE, MASE).
- Masukkan `daily_visits` sebagai regressor tambahan.

4. Ekspansi Kategori Model 3

- Lengkapi mapping sehingga benar-benar mencakup 16 poliklinik sesuai domain RSUD.
- Terapkan teknik handling imbalanced (class weights, oversampling) jika distribusi sangat timpang.

CONCLUSION & INSIGHT

- Analisis berhasil membangun pipeline Machine Learning end-to-end dengan tiga model utama untuk klasifikasi dan peramalan.
- XGBoost mencapai akurasi 83.08% untuk klasifikasi biner, sementara Random Forest unggul pada klasifikasi multi-kelas dengan akurasi 84.57%.
- Prophet mampu menangkap pola musiman mingguan dengan performa peramalan yang baik ($R^2 = 0.39$).
- Pipeline NLP klinis berhasil mengekstraksi entitas penting dan menghasilkan 8 fitur terstruktur untuk meningkatkan kualitas model.
- Analisis mencakup 24.806 data pasien, mulai dari EDA, feature engineering, hingga evaluasi dan perbandingan model.
- Disusun roadmap implementasi 12 minggu dengan strategi mitigasi risiko yang jelas.

THANK YOU.

09 May, 2026

Creative Presentation

Presented By: Greta Mae Evans

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat.

@reallygreatsite

reallygreatsite.com

hello@reallygreatsite.com

123 Anywhere St., Any City, ST 12345